


一张图理解 SAE : feature 到底是什么？



一个 feature 的定义

Feature j 不是一个人工标签，也不等于一个单词。它由同一个 SAE 中的一对对象定义：


$z_{t,j}$

该 token 上 feature j 的激活强度

$w_j = W_{dec}[j, :]$

feature j 指向 residual space 的 decoder direction

同一条轨迹中，每个 token 都有一组稀疏 feature activations



如何给 feature 起名字？

1. 找它最高激活的 token/context
2. 看跨问题是否重复出现同一模式
3. 做 token injection、scrubbing、paraphrase
4. 通过后才给语义标签

本项目中的 feature ID

F11983 只在 layer 17, k=64 这个 SAE 内有意义。
换 layer、换 k、换 SAE seed 后，需要匹配 decoder
direction，不能直接比较相同数字 ID。