

什么叫 short feature / long feature ?

1. 它们是训练完成后的统计关联，不是训练标签

$$A_j^{full}(\tau) = \frac{1}{T} \sum_{t=1}^T z_{t,j}$$

全 sequence：该 feature 在整条回答中平均有多强

$$A_j^{64}(\tau) = \frac{1}{\min(T, 64)} \sum_{t < 64} z_{t,j}$$

前 64 token：该 feature 是否在轨迹早期已经出现


$$\Delta_j = \text{mean}_q[A_j(\text{short})] - \text{mean}_q[A_j(\text{long})]$$

$\Delta_j > 0$: short-associated


$\Delta_j < 0$: long-associated

同一问题内配对，再跨问题检验

3. feature 在轨迹的什么位置出现？



4. 全 sequence 与前 64 token



2. 真实 feature 例子

Short F11983

最高激活 token: Answer
96.3% activation mass 在 Answer
full d=+2.28, first-64 d=+0.06

Long F3934

最高激活 token: \n
公式块、换行和步骤格式
full d=-0.84, first-64 d=-0.15

所以 feature ID 本身没有名字；
名字来自 activation contexts 和 falsification。

5. 当前可以怎样解释？

观察到的 short features

主要是 Answer / 冒号等收尾信号
更像 final-answer density
不应直接拿来 steering

观察到的 long features

公式换行、步骤编号、Find/Substituting
在 early prefix 已部分出现
仍可能只是 style/lexical cue

尚不能声称

不是 pre-generation 的 short/long intent
不是 student teaching utility
不是已证实的 extra computation
需要 injection/scrubbing/paraphrase/steering